

Uogólnione Modele Liniowe

dr n. o zdr. Urszula Cwalina | Spis treści wykładów

Wykład 06 | GLM – wprowadzenie i regresja logistyczna cz. 1

- 1. Motywacja – dlaczego modele?**
zmienne wklajające, kierunek i siła efektu, predykcja, wiele zmiennych
- 2. Ogólny model liniowy (General linear model)**
zapis macierzowy, składnik losowy $\varepsilon_i \sim N(0, \sigma^2)$
- 3. GLM – 3 komponenty**
losowy, systematyczny (predyktor liniowy), funkcja wiążąca (link)
- 4. Rodzina wykładnicza rozkładów prawdopodobieństwa**
dwumianowy, Poissona, normalny
- 5. Funkcje wiążące – przykłady**
identity, logarytm, logit, probit, log-log, cloglog
- 6. GLM w R – rodziny i dostępne funkcje łączące**
binomial, gaussian, poisson, quasi
- 7. Założenia GLM**
niezależność obserwacji, błąd tylko w zmiennej zależnej
- 8. Regresja logistyczna – motywacja**
zmienna binarna, ograniczenia regresji liniowej
- 9. Model logitowy – definicja**
funkcja logistyczna $\pi(x) = e^z / (1 + e^z)$, związek logit–prawdopodobieństwo
- 10. Probit czy logit? – porównanie**
kształt krzywych, interpretacja przez OR, praktyczne wskazówki; wykres probit/logit/cloglog
- 11. Przykład: Żuczki**
logit vs probit vs cloglog w Stata, porównanie AIC i log-likelihood
- 12. Przykład: CHD**
dane (100 osób, wiek, choroba wieńcowa), wykresy, model `glm()` w R

Wykład 07 | Regresja logistyczna cz. 2

- 1. Interpretacja modelu – iloraz szans (OR)**
 $OR = e^{\beta_1}$, wzrost predyktora o 1 jednostkę, warunek braku efektu $OR = 1$
- 2. Przewidywane prawdopodobieństwo i MEL**
obliczanie $\pi(x)$, median effective level $= -\alpha/\beta_1$
- 3. Przedziały ufności dla efektu (e^β)**
95% PI dla β i dla $\exp(\beta)$, interpretacja

4. **Test istotności – statystyka Walda**
 $z = \hat{\beta}/ASE$, wersja z i χ^2_1
5. **Statystyka testu ilorazu wiarygodności (LRT)**
 $G^2 = -2\log(L_0/L_1)$, rozkład χ^2_1 , przewaga nad Waldem przy małych próbach
6. **Rozkład estymatorów prawdopodobieństwa**
ASE logitu, 95% PI dla $\pi(x_0)$, macierz kowariancji `vcov()`
7. **Ocena dopasowania modelu – dewiancja D^2**
model vs model nasycony, założenie $n_j \geq 5$ dla 75% podgrup
8. **Ocena dopasowania – statystyka Pearsona X^2**
definicja, rozkład χ^2_{R-p}
9. **Modele zagnieżdżone – LRT**
 $G^2(M_1|M_2) = D^2_{M_1} - D^2_{M_2}$, tabela porównań (vs nasycony / vs zagnieżdżony)
10. **Przykład: CHD**
`lrtest()`, `vcov()`, PI dla $\pi(67)$, Wald vs LRT
11. **Przykład: TOXIC**
model liniowy i kwadratowy dawki, porównanie dewiancji, wybór modelu

Wykład 08 | Regresja logistyczna cz. 3 – Hosmer-Lemeshow & Overdispersion

1. **Reszty Pearsona – standardowe (unadjusted)**
definicja, asymptotyczny rozkład $N(0,1)$, wykrywanie braku dopasowania ($|r_j| > 2$)
2. **Reszty Pearsona – adjusted (leverage)**
własności dźwigni h_j , reguła $h_j > 2\bar{h}$
3. **Reszty dewiancji**
definicja, znak jak $y_j - n_j\hat{\pi}_j$, adjusted deviance residuals
4. **Diagnostyka graficzna reszt**
obserwowane vs oczekiwane proporcje, reszty vs zmienne objaśniające
5. **Reszty w R**
`resid(type="pearson")`, `resid(type="deviance")`, `hatvalues()` – przykład TOXIC
6. **Problem ciągłego predyktora a ocena dopasowania**
małe podgrupy, dwie strategie: grupowanie lub Hosmer-Lemeshow
7. **Statystyka Hosmer-Lemeshow**
podział na g grup (decyle), $(g-1)$ indyktorów, $\hat{C} \sim \chi^2_{g-2}$
8. **Przykład: CHD**
`hoslem.test()` z pakietu `ResourceSelection`, interpretacja p -value
9. **Overdispersion – definicja i przyczyny**
pominięta zmienna, interakcje, obserwacje odstające, korelacja, zła funkcja łącząca
10. **Miara rozrzutu – skalowanie ($\hat{\phi}$)**
skalowana dewiancja D^2/df , skalowana statystyka Pearsona X^2/df , wartości > 1

11. Przykład: Szczurki

model dwumianowy w R, wykrycie overdispersion przez p -value i χ^2/df

12. Korekcja overdispersion

`glm.binomial.disp()` z pakietu `dispmod`, ważona estymacja, wpływ na SE i p -value

Wykład 09 | Regresja logistyczna wielokrotna

1. Regresja logistyczna wielokrotna — wprowadzenie

zmienne jakościowe i ilościowe, zmienne dummy, interakcje

2. Zmienne sztuczne (dummy)

kodowanie zmiennych nominalnych, kategoria odniesienia, interpretacja OR

3. Tabele wielodzielcze — model addytywny

brak interakcji, jednorodność ilorazów szans (OR)

4. Warunkowa niezależność

test LR, statystyka Walda, test Cochran-Mantel-Haenszel (CMH)

5. Wspólny OR (common conditional OR)

estymacja ML, estymator Mantel-Haenszel

6. Jednorodność OR

statystyka Breslow-Day, testy χ^2 i G^2

7. Kryteria porównywania modeli

AIC, BIC, test ilorazu wiarygodności (LRT)

8. Przykład: AZT/AIDS

wspólny conditional OR, test warunkowej niezależności i jednorodności, wyniki w R

9. Przykład: Horseshoe Crab

zmienne dummy dla koloru, interakcje kolor $\times$ szerokość, test LR dla koloru, interpretacja OR

Wykład 10 | Modele logitowe dla zmiennych o wielu kategoriach

1. Przegląd modeli dla zmiennych wielokategorialnych

baseline logits, adjacent logits, continuation ratio logits, proportional odds

2. Rozkład wielomianowy

prawdopodobieństwa kategorii, średnia i wariancja

3. Baseline logits model (nominalna regresja logistyczna)

kategoria odniesienia, ryzyko względne, interpretacja β , OR między dowolnymi kategoriami

4. Kryteria informacyjne AIC, AIC_c, BIC

definicje, kiedy stosować, porównanie modeli

5. Adjacent logits model (porównanie sąsiednich kategorii)

OR, common slopes, partial common slopes, acat w VGAM

6. Continuation ratio logits model (model warunkowy)

wariant forward i reverse, OR, common slopes, cratio w VGAM

7. Cumulative-logits model

skumulowany logit, OR, common slopes

8. Regresja proporcjonalnych szans (proportional odds)

własności, zmiana kodów/kolejności kategorii, łączenie kategorii, propodds w VGAM

9. Inne funkcje łączące

probit w modelu skumulowanym (`cumulative(link="probit")`)

10. Przykład: Mental Health

R: VGAM, nnet, effects; porównanie wszystkich modeli (AIC/BIC/LRT); interpretacja OR; wykresy efektów

Wykład 11 | Quasi-wiarygodność, GEE

1. Modele dla zgrupowanych danych binarnych

quasi-wiarygodność, GEE — przegląd podejść

2. Overdispersion (nadmierny rozrzut)

rozpoznawanie przez χ^2 i D^2 , możliwe przyczyny, konsekwencje (zaniżone SE)

3. GLM — przypomnienie

rodzina wykładnicza, predyktor liniowy, równania ML

4. Największa wiarygodność (ML)

logarytm funkcji wiarygodności, równania estymujące, idea quasi-likelihood

5. Quasi-wiarygodność

beta-binomial variance function, parametr dyspersji ϕ , estymacja przez $\chi^2/(n-p)$

6. Metody numeryczne ML

Newton-Raphson, Fisher scoring, IRWLS

7. Średnia i wariancja w rodzinie wykładniczej

powiązanie $E(Y)$ i $\text{Var}(Y)$ przez funkcję wariancji

8. Metody oparte o quasi-wiarygodność

odporność na overdispersion, brak założeń o rozkładzie Y

9. Największa quasi-wiarygodność

funkcja quasi-wiarygodności, warunki redukcji do ML

10. Przykład: Żelazo

glm (binomial) vs glm (quasibinomial); GEE exchangeable i independence na danych zagregowanych i indywidualnych (gee)

11. Idea GEE — uogólnione równania estymujące

analiza powtarzanych pomiarów, modele brzegowe, struktura wariancji-kowariancji

12. GEE — kolejne etapy estymacji

model brzegowy, working correlation matrix, robust SE

13. GEE — working correlation matrix

independence, exchangeable, unstructured, autoregressive

14. Przykład: Aborcja

GEE independence vs exchangeable; naive SE vs robust SE; wnioski o płci i sytuacji

1. **Modele z efektami losowymi (random effects)**
model logitowo-normalny, efekt losowy klastra $u_i \sim N(0, \sigma_u^2)$, korelacja wewnątrz klastra
2. **Przykład: Żelazo — GLMM**
glmer (aproksymacja Laplace'a) vs glmer (kwadratura Gaussa-Hermite'a, nAGQ=100); interpretacja wariancji efektu losowego
3. **Przykład: Insomnia — opis badania**
podwójnie ślepa próba, lek vs placebo, czas zasypiania przed i po 2 tygodniach leczenia
4. **Clustered multinomial models — przegląd**
rozszerzenia: quasi-wiarygodność, GEE, modele z efektami losowymi
5. **Regresja proporcjonalnych szans — model GEE dla Insomnia**
predyktor z okazją, leczeniem i interakcją; interpretacja β_1, β_3
6. **GEE dla danych porządkowych**
ordLORgee: LORstr="independence" vs "category.exch"; local odds ratios
7. **Interpretacja wyników GEE — Insomnia**
efekt czasu w grupie placebo (e^{β_1}) vs w grupie z lekiem ($e^{\beta_1 + \beta_3}$)
8. **Rozszerzenie do GLMM dla danych porządkowych**
model z efektem losowym dla pacjenta, $u_i \sim N(0, \sigma_u^2)$, korelacja między okazjami
9. **GLMM dla Insomnia**
clmm z pakietu ordinal, nAGQ=40; progi (*threshold coefficients*); wariancja efektu losowego
10. **Porównanie GEE vs GLMM**
modele populacyjne (brzegowe) vs warunkowe; współczynniki wyższe w GLMM; tabela porównawcza